

Informe final - Proyecto Integrador Minería de Datos 1

Integrante: Sanchez Luna Fernando Emmanuel. Repositorio: https://github.com/ferlusa90/mineria_de_datos_TF. Aplicacion Streamlit: <https://mineriadedatostf-a4hvlnmrwzjjvazcprcx7q.streamlit.app/>.

Contexto y objetivo

Se analiza una base de usuarios de una plataforma de streaming. El objetivo es convertir un dataset con problemas reales de calidad en una base confiable, trazable y lista para analizar patrones de consumo, soporte y preferencias de contenido.

Dataset y calidad inicial

La base original contiene 8160 filas y 8 columnas. Cada fila representa un usuario e incluye edad, plan, pais, genero favorito, minutos mensuales vistos, ultimo login y tickets de soporte. En la inspeccion se detectaron nulos, duplicados, user_id repetidos, categorias escritas de varias formas, fechas invalidas/futuras, edades imposibles, consumos negativos/extremos y tickets negativos/extremos.

Decisiones de limpieza y preparacion

Se preservó el JSON original en data/raw/ y se trabajó sobre una copia. Primero se eliminaron duplicados exactos. Luego, para user_id repetidos, se eligió la fila de mayor calidad: fecha real, consumo mensual plausible, cercanía al consumo típico y mayor completitud. Las categorías de plan, país y genero favorito fueron estandarizadas sin crear columnas nuevas.

Los valores imposibles se convirtieron a nulos antes de imputar: edades fuera de 13-100, tiempos negativos, tickets negativos y fechas invalidas o posteriores a la fecha de referencia. La imputación usó medianas segmentadas para variables numericas y modas para categoricas. Se aplicó winsorización superior en consumo mensual y tickets para evitar que extremos poco realistas distorsionaran graficos, medidas resumen y PCA.

Trazabilidad ETL

Paso	Filas	Nulos	Retencion
0	8160	753	100.0
1	8034	753	98.46
2	8000	743	98.04
3	8000	743	98.04
4	8000	1019	98.04
5	8000	0	98.04
6	8000	0	98.04
7	8000	0	98.04

Hallazgos del analisis exploratorio

El consumo mensual muestra concentracion central y una cola de usuarios intensivos. La edad aporta contexto, pero no explica por si sola el comportamiento de visualizacion. Al incorporar plan, tickets de soporte y genero favorito, aparecen perfiles mas utiles: usuarios de mayor intensidad, posibles puntos de friccion y preferencias de contenido que ayudan a orientar nuevas preguntas de negocio.

PCA

PCA se aplicó sobre age, monthly_watch_time_mins y customer_support_tickets. Antes se usó estandarización Z-score porque las variables tienen unidades distintas: años, minutos y cantidad de tickets. PCA se interpreta como una síntesis exploratoria de perfiles numericos, no como modelo predictivo ni prueba de causalidad.

Conclusiones y limitaciones

La conclusión principal es metodologica y analitica: antes de interpretar, hay que preparar bien los datos. La base final queda sin nulos, sin duplicados y con la estructura original preservada. A nivel de negocio, consumo, soporte, plan, edad y genero favorito aportan piezas distintas para describir perfiles de usuario.

Las conclusiones son descriptivas. No se cuenta con churn, antigüedad, precio pagado, satisfacción, dispositivo ni historial detallado de sesiones, por lo que no corresponde afirmar causas ni predecir abandono. Como mejora futura se recomienda incorporar variables temporales y comerciales para analizar retencion, riesgo de baja y valor del usuario.

Enlaces

GitHub: https://github.com/ferlusa90/mineria_de_datos_TF

Streamlit: <https://mineriadedatostf-a4hvlnmrwzjjvazcprcx7q.streamlit.app/>