

Proyecto Integrador - Minería de Datos 1

Analisis de usuarios de una plataforma de streaming

Integrante: Sanchez Luna Fernando Emmanuel

Comision: ITSE NODO TARDE

Fecha: 28/06/2026



1. Objetivo del trabajo

El objetivo fue preparar y analizar una base de usuarios de streaming con problemas reales de calidad. El enfoque usado fue el de un analista de datos junior: primero diagnosticar, después justificar la limpieza, aplicar el código y finalmente validar el resultado antes de interpretar.

2. Dataset

Indicador	Valor
Filas originales	8,160
Filas finales	8,000
Columnas finales	8
Nulos finales	0
Duplicados exactos finales	0
user_id repetidos finales	0
Retencion final	98.04%

3. Metodologia de limpieza

La limpieza se documentó con una secuencia reproducible: diagnóstico, decisión, código aplicado y control posterior. Esta forma permite defender cada transformación y evita borrar o imputar datos sin evidencia.

Ejemplo de diagnostico antes de limpiar duplicados:

```

duplicados_exactos = raw[raw.duplicated(keep=False)]
user_id_repetidos = raw[raw.duplicated("user_id", keep=False)]

print(raw.duplicated().sum())
print(raw.duplicated("user_id").sum())
user_id_repetidos.sort_values("user_id").head(20)

```

Para user_id repetidos no se eligio una fila al azar. Se priorizo fecha valida, consumo plausible, consumo cercano al valor tipico, login mas reciente y mayor completitud.

```

orden = ordenar_usuarios_repetidos(df)
df = (
    df.loc[orden]
    .drop_duplicates(subset="user_id", keep="first")
    .sort_values("user_id")
    .reset_index(drop=True)
)

```

4. Log de transformaciones

Paso	Decision	Filas	Nulos	Retencion
0	Carga del dataset original en una copia de trabajo.	8160	753	100.0%
1	Eliminacion de duplicados exactos.	8034	753	98.46%
2	Resolucion de user_id repetidos con ranking de calidad.	8000	743	98.04%
3	Estandarizacion de categorias equivalentes.	8000	743	98.04%
4	Conversion de valores imposibles a nulos.	8000	1019	98.04%
5	Imputacion de nulos con medianas, modas y fecha mediana.	8000	0	98.04%
6	Winsorizacion superior de consumo mensual y tickets.	8000	0	98.04%
7	Normalizacion final de tipos y exportacion.	8000	0	98.04%

5. Analisis exploratorio

El EDA muestra que el consumo mensual es una variable central para describir intensidad de uso. La edad aporta contexto, pero no explica por sí sola el comportamiento. El plan, el género favorito y los tickets de soporte permiten pensar perfiles más completos.

6. PCA

PCA se aplicó sobre `age`, `monthly_watch_time_mins` y `customer_support_tickets` después de estandarizar. El escalamiento fue necesario porque las variables tienen unidades distintas: años, minutos y cantidad de tickets. PCA ayuda a resumir variables numéricas, pero no reemplaza la interpretación del EDA.

7. Limitaciones

El dataset no incluye churn, fecha de alta, antigüedad, precio pagado, satisfacción, dispositivo ni historial detallado de sesiones. Por eso las conclusiones son descriptivas: muestran patrones observados, no causas definitivas.

8. Conclusion final

El proyecto deja una base ordenada, trazable y lista para análisis. La conclusión más importante es metodológica: antes de interpretar, hay que preparar bien los datos. Sin esa etapa, el análisis puede sonar convincente, pero apoyarse en errores de carga, duplicados o extremos poco realistas.