

Informe final - Proyecto Integrador Minería de Datos 1

Integrante: Sanchez Luna Fernando Emmanuel. Comision: tarde. Fecha: 28/06/2026.

Criterio de formato: este PDF no incluye código ni gráficos. Para cumplir la guía, usa texto, tablas pequeñas y enlaces. Las visualizaciones completas están en Streamlit y en los notebooks.

Contexto y objetivo

Se analiza una base de usuarios de streaming con problemas reales de calidad. El objetivo fue construir un proceso reproducible: inspeccionar, preparar datos con decisiones justificadas, realizar EDA, aplicar PCA y comunicar resultados.

Dataset y calidad inicial

Cada registro representa un usuario e incluye user_id, edad, plan, consumo mensual, país, género favorito, último login y tickets de soporte. La inspección detectó nulos, duplicados, user_id repetidos, categorías inconsistentes, fechas inválidas/futuras, edades imposibles y valores extremos.

Indicador	Inicial	Final
Filas	8160	8000
Columnas	8	8
Nulos totales	753	0
Duplicados exactos	126	0
user_id repetidos	160	0
Retención	100.00%	98.04%

Categorías finales estandarizadas: planes Básico/Estandar/Premium; países Argentina, Brasil, Chile, Colombia, México, Perú y Uruguay; géneros Acción, Comedia, Crimen, Documental, Drama, Romance y Thriller.

Decisiones de limpieza y preparación

Se preservó el JSON original en data/raw/ y se trabajó sobre una copia. Los duplicados exactos se eliminaron. Los user_id repetidos se resolvieron con ranking de calidad: fecha real, consumo plausible, cercanía al consumo típico, fecha reciente y completitud.

Los valores imposibles se convirtieron a nulos antes de imputar. La imputación usó medianas y modas, priorizando segmentos cuando era posible. La winsorización superior se aplicó a consumo mensual y tickets para que extremos poco realistas no distorsionaran el análisis.

Paso	Decisión	Filas	Nulos
0	Carga del dataset original en una copia de trabajo.	8160	753
1	Eliminación de duplicados exactos.	8034	753
2	Resolución de user_id repetidos con ranking de ca...	8000	743
3	Estandarización de categorías equivalentes.	8000	743
4	Conversión de valores imposibles a nulos.	8000	1019
5	Imputación de nulos con medianas, modas y fecha m...	8000	0
6	Winsorización superior de consumo mensual y tickets.	8000	0
7	Normalización final de tipos y exportación.	8000	0

Hallazgos del análisis exploratorio

Análisis	Lectura principal
Univariado	Consumo mensual concentrado en valores medios, con cola de usuarios intensivos.
Univariado	La composición por plan contextualiza comparaciones posteriores.
Bivariado	La edad aporta contexto, pero no explica por sí sola el consumo.
Bivariado	El consumo por plan permite comparar medianas y dispersión.
Multivariado	Edad, consumo y género favorito ayudan a interpretar perfiles de contenido.

La evidencia sugiere que el consumo no debe leerse con una única variable. La edad aporta contexto, pero los perfiles se entienden mejor combinando consumo, plan y género favorito.

PCA

PCA se aplicó sobre age, monthly_watch_time_mins y customer_support_tickets. Antes se usó estandarización Z-score porque las variables tienen unidades distintas: años, minutos y cantidad de tickets. PCA se interpreta como síntesis exploratoria, no como modelo predictivo ni prueba de causalidad.

Conclusiones y limitaciones

La conclusión principal es metodológica: antes de interpretar, hay que preparar bien los datos. La base final queda sin nulos, sin duplicados, con user_id únicos y con estructura original preservada. Esto permite analizar consumo, soporte, plan, edad y género favorito con mayor confianza.

Limitación central: el dataset no incluye churn, fecha de alta, antigüedad, precio pagado, satisfacción, dispositivo ni historial detallado de sesiones. Por eso las conclusiones son descriptivas y no causales. Como mejora futura se recomienda incorporar variables temporales y comerciales.

Enlaces

Repositorio GitHub: https://github.com/ferlusa90/mineria_de_datos_TF

Aplicación Streamlit: <https://mineriadedatos1f-a4hvlnmwzjjvazcprcx7q.streamlit.app/>