



Informe final - Proyecto Integrador Minería de Datos 1

Análisis de usuarios de una plataforma de streaming

Integrante: Sanchez Luna Fernando Emmanuel | **Comisión:** tarde | **Fecha:** 28/06/2026

1. Contexto y objetivo

En este proyecto revise un dataset de usuarios de streaming con problemas de calidad. El recorrido fue: inspeccionar la base, limpiar con reglas explicadas, hacer EDA univariado, bivariado y multivariado, aplicar PCA y comunicar los resultados.

El criterio principal fue no limpiar por costumbre. Primero mire la evidencia, después aplique una regla y al final controle que cambio produjo.

2. Dataset y calidad inicial

Cada registro representa un usuario e incluye identificador, edad, plan, consumo mensual, país, género favorito, fecha de último login y tickets de soporte. La inspección inicial detectó nulos, duplicados, user_id repetidos, categorías inconsistentes, fechas inválidas/futuras, edades imposibles y valores extremos.

Indicador	Estado inicial	Estado final
Filas	8160	8000
Columnas	8	8
Nulos totales	753	0
Duplicados exactos	126	0
Filas con user_id repetido	160	0
Retención de filas	100%	98.04%

Grafico 1. Impacto de la limpieza

Este gráfico no está repetido en Streamlit. Resume cómo cambian los nulos durante el pipeline ETL: primero aumentan cuando marco valores imposibles y después bajan a cero con la imputación.




Grafico 1: nulos totales por paso del pipeline ETL.



3. Decisiones de limpieza y preparacion

Conserve el JSON original en data/raw/ y trabaje sobre una copia. Primero saque duplicados exactos. Después resolví user_id repetidos con un ranking de calidad: fecha real, consumo mensual plausible, cercanía al consumo típico, fecha más reciente y completitud.

También uní categorías que significaban lo mismo para no crear grupos falsos por escritura. Los valores imposibles los pase a nulos antes de imputar. Para completar faltantes use medianas y modas, priorizando segmentos cuando había información suficiente. La winsorización superior se aplicó a consumo mensual y tickets para que algunos extremos no dominaran el análisis sin tener que borrar usuarios.

Paso	Decision	Filas	Nulos
0	Carga del dataset original en una copia de trabajo.	8160	753
1	Eliminación de duplicados exactos.	8034	753
2	Resolución de user_id repetidos con ranking de calidad.	8000	743
3	Estandarización de categorías equivalentes.	8000	743
4	Conversión de valores imposibles a nulos.	8000	1019
5	Imputación de nulos con medianas, modas y fecha mediana.	8000	0
6	Winsorización superior de consumo mensual y tickets.	8000	0
7	Normalización final de tipos y exportación.	8000	0


4. Hallazgos del análisis exploratorio

El EDA se organizó como pide la guía: dos visualizaciones univariadas, dos bivariadas y una multivariada. En cada caso no solo describo el gráfico; también dejo que lectura aporta para entender a los usuarios.

- Univariado - consumo mensual: consumo mediano de 772.4 minutos y promedio de 809.0 minutos. La distribución muestra usuarios de consumo medio y una cola de usuarios intensivos.
- Univariado - plan: la composición por plan muestra cuánto pesa cada segmento, algo importante antes de comparar grupos.
- Bivariado - edad y consumo: la correlación edad-consumo es 0.007. La edad suma contexto, pero no explica sola el consumo.
- Bivariado - consumo por plan: las medianas por plan muestran diferencias claras: Premium: 1123.6, Estandar: 840.6, Básico: 553.6 minutos.
- Multivariado - edad, consumo y género favorito: el género favorito agrega una lectura de perfil. No lo tomo como causa directa, pero sí como una pista para seguir revisando preferencias de contenido.

Grafico 2. Consumo mediano por género favorito

Este gráfico tampoco repite los gráficos de Streamlit. Resume numéricamente el análisis multivariado vinculado a preferencias: muestra que géneros presentan mayor consumo mediano mensual.





INSTITUTO TECNOLÓGICO DE SANTIAGO DEL ESTERO
Grafico 2: minutos mensuales medianos agrupados por genero favorito.

Genero favorito	Consumo mediano
Documental	800.5 min
Thriller	782.8 min
Crimen	780.8 min
Accion	773.0 min
Romance	762.4 min
Comedia	762.1 min
Drama	761.5 min

5. PCA

PCA se aplico sobre age, monthly_watch_time_mins y customer_support_tickets. Antes se uso estandarizacion Z-score porque las variables tienen unidades distintas: años, minutos y cantidad de tickets. Sin escalar, la variable de mayor magnitud podría dominar el resultado.

PCA lo interpreto como una síntesis exploratoria de variables numéricas. No es un modelo predictivo ni una prueba de causalidad; sirve para ver si edad, consumo y soporte muestran algún patrón cuando se resumen en menos dimensiones.

6. Conclusiones y limitaciones

La conclusión de limpieza es directa: la base original no estaba lista para analizar. Tenía duplicados, user_id repetidos, nulos, categorías inconsistentes, fechas inválidas y extremos. La preparación dejó una base final de 8000 usuarios, sin nulos, sin duplicados y con categorías consistentes. Con eso el EDA y PCA parten de una base más confiable.

En el análisis univariado, el consumo mensual aparece concentrado en valores medios, pero con una cola de usuarios intensivos. Por eso conviene mirar medidas robustas y no quedarse solo con el promedio. La composición por plan ayuda a entender el peso de cada segmento.

En el análisis bivariado, la edad por sí sola no explica el consumo; el plan muestra diferencias más claras en consumo mediano. En el cruce multivariado, el género favorito suma una pista de perfil: algunos géneros concentran consumos medianos más altos, aunque eso no alcanza para hablar de causa.

La principal limitación es que el dataset no incluye churn, fecha de alta, antigüedad, precio pagado, satisfacción, dispositivo ni historial detallado de sesiones. Por eso las conclusiones son descriptivas y no causales. Como mejora, agregaría variables temporales y comerciales para estudiar retención, riesgo de baja y valor del usuario.

7. Enlaces y reproducibilidad

Repositorio GitHub: https://github.com/ferlusa90/mineria_de_datos_TF

Aplicación Streamlit: <https://mineriadedatostf-a4hvlmrwzjjvazcprcx7q.streamlit.app/>

El repositorio incluye dataset original y procesado, notebooks ejecutables, requirements.txt, pipeline_log.csv, aplicación Streamlit e informes en reports/.