

Proyecto Integrador - Minería de Datos 1

Analisis de usuarios de una plataforma de streaming

Integrante: Sanchez Luna Fernando Emmanuel

Comision: ITSE NODO TARDE

Fecha: 28/06/2026



1. Objetivo del trabajo

El objetivo fue preparar y analizar una base de usuarios de streaming con problemas reales de calidad. El enfoque usado fue el de un analista de datos junior: primero diagnosticar, despues justificar la limpieza, aplicar el codigo y finalmente validar el resultado antes de interpretar.

2. Dataset

Indicador	Valor
Filas originales	8,160
Filas finales	8,000
Columnas finales	8
Nulos finales	0
Duplicados exactos finales	0
user_id repetidos finales	0
Retencion final	98.04%

3. Metodologia de limpieza

La limpieza se documento con una secuencia reproducible: diagnostico, decision, codigo aplicado y control



```
duplicados_exactos = raw[raw.duplicated(keep=False)]
user_id_repetidos = raw[raw.duplicated("user_id", keep=False)]
```

```
print(raw.duplicated().sum())
print(raw.duplicated("user_id").sum())
user_id_repetidos.sort_values("user_id").head(20)
```

Para user_id repetidos no se eligió una fila al azar. Se priorizó fecha válida, consumo plausible, consumo cercano al valor típico, login más reciente y mayor completitud.

```
orden = ordenar_usuarios_repetidos(df)
df = (
    df.loc[orden]
    .drop_duplicates(subset="user_id", keep="first")
    .sort_values("user_id")
    .reset_index(drop=True)
)
```

4. Log de transformaciones

Paso	Decision	Filas	Nulos	Retencion
0	Carga del dataset original en una copia de trabajo.	8160	753	100.0%
1	Eliminación de duplicados exactos.	8034	753	98.46%
2	Resolución de user_id repetidos con ranking de calidad.	8000	743	98.04%
3	Estandarización de categorías equivalentes.	8000	743	98.04%
4	Conversión de valores imposibles a nulos.	8000	1019	98.04%
5	Imputación de nulos con medianas, modas y fecha mediana.	8000	0	98.04%
6	Winsorización superior de consumo mensual y tickets.	8000	0	98.04%
7	Normalización final de tipos y exportación.	8000	0	98.04%



5. Analisis exploratorio

El EDA muestra que el consumo mensual es una variable central para describir intensidad de uso. La edad aporta contexto, pero no explica por sí sola el comportamiento. El plan, el género favorito y los tickets de soporte permiten pensar perfiles más completos.

6. PCA

PCA se aplicó sobre age, monthly_watch_time_mins y customer_support_tickets después de estandarizar. El escalamiento fue necesario porque las variables tienen unidades distintas: años, minutos y cantidad de tickets. PCA ayuda a resumir variables numéricas, pero no reemplaza la interpretación del EDA.

7. Limitaciones

El dataset no incluye churn, fecha de alta, antigüedad, precio pagado, satisfacción, dispositivo ni historial detallado de sesiones. Por eso las conclusiones son descriptivas: muestran patrones observados, no causas definitivas.

8. Conclusion final

El proyecto deja una base ordenada, trazable y lista para análisis. La conclusión más importante es metodológica: antes de interpretar, hay que preparar bien los datos. Sin esa etapa, el análisis puede sonar convincente, pero apoyarse en errores de carga, duplicados o extremos poco realistas.